SPRINT 2 · GRUPO 12 · 2026.1

The Green Grid

Detecção de Doenças em Plantas
com Computação Distribuída

Arthur Clemente · Diego Moreira · Felipe Vilhena · Iago Fereguetti · Luan Carrieiros · Lucas Hauck

Trabalho Interdisciplinar VI

PUC Minas · 2026.1

PlantVillage · 54k imagens

Contextualização e Problema

MOTIVAÇÃO

- Doenças vegetais causam até **40% de perdas** nas colheitas mundiais por ano (FAO, 2021)
- Diagnóstico manual exige agrônomos especializados, recurso escasso em regiões rurais
- Detecção tardia amplifica danos: sintomas visíveis apenas em estágio avançado

DELIMITAÇÃO DO CENÁRIO E TAREFA

Cenário: laboratorial controlado
Imagens PlantVillage com fundo branco uniforme, não representativo de condições de campo real.

Tipo de tarefa: Classificação supervisionada multiclasse: 38 classes · 14 culturas · 224×224 px

Limitação reconhecida: generalização para campo (fundo variável, iluminação natural) é questão em aberto, discutida neste trabalho.

Objetivos Mensuráveis e Contribuição Técnica

OBJETIVO 1 · QUALIDADE

Acurácia ≥ 90% em *color_test.txt* (10.709 imgs, 38 classes)

94,78% · atingido

OBJETIVO 2 · PARALELISMO

Speedup ≥ 1,5×, Ray 2 nós comparado com baseline sequencial

1,41× · parcial

2 GPUs para 3 actors

OBJETIVO 3 · ENSEMBLE

Ensemble supera melhor modelo individual em comparação justa

+0,52 pp (stacking c+s)

Contribuição técnica: medição empírica do speedup decomposto por nível de paralelismo (CUDA / DataLoader / Ray), aspecto raramente explorado na literatura de detecção de doenças vegetais, que costuma focar exclusivamente em acurácia.

Dataset: PlantVillage

54k
imagens totais

38
classes (26 doenças + 12 saudável)

14
culturas distintas

80/20
43.596 treino · 10.709 teste

ESTRUTURA DO DATASET

- 3 versões: **color · grayscale · segmented** (segmentação ExG: 2G−R−B > 0,1), com 1 Ray actor treinado por versão
- Split 80/20 com proteção de *leaf_id*: a mesma folha não aparece em treino e teste · Fonte: Hughes & Salathé (2015) · CC-BY-SA-3.0

LIMITAÇÃO CONHECIDA

Viés de fundo (Noyan, 2022): modelos treinados no PlantVillage caem de 99% para 31% em imagens in-the-wild. O fundo branco uniforme pode ser classificado pela CNN como feature discriminativa em vez da lesão.

Revisão da Literatura

O QUE CADA TRABALHO CONTRIBUIU PARA O PROJETO

MOHANTY ET AL. (2016) · REFERÊNCIA SEMINAL

TL AlexNet/GoogLeNet → 99% no PlantVillage

Estabelece o benchmark de acurácia no mesmo dataset e confirma a viabilidade de transfer learning; embasou a escolha do ResNet-18 com backbone pré-treinado ImageNet.

SHOAIB ET AL. (2023) · SURVEY 135 ARTIGOS

Estado da arte: TL é o padrão dominante

Panorama das arquiteturas atuais (2015–2022); justifica o uso de backbone congelado como abordagem adequada para datasets de tamanho médio.

NOYAN (2022) · ANÁLISE DE VIÉS DE CAPTURA

99% no PlantVillage → 31% in-the-wild

Motivou a segmentação ExG para mitigar viés de fundo e a delimitação explícita do cenário como "laboratorial controlado" nos objetivos do projeto.

BARBEDO (2022) · REPRESENTATIVIDADE DE DADOS

Dados laboratoriais ≠ condições de campo real

Reforça a limitação reconhecida neste trabalho e justifica a validação em campo real prevista para o Sprint 3.

Acurácias acima de 94% em trabalhos relacionados: backbone fine-tuned completo, maior custo computacional. Nosso escopo é treino distribuído com medição empírica de speedup por nível de paralelismo.

Arquitetura: ResNet-18 com Transfer Learning

ESPECIFICAÇÃO DO MODELO

```
Input: 224 × 224 × 3
↓ Conv1 (7×7, 64 ch, stride=2)
↓ MaxPool (3×3, stride=2)
↓ Layer1–4: 8 blocos residuais ← frozen
   64 → 128 → 256 → 512 canais
↓ AvgPool global → 512-dim
↓ FC: Linear(512 → 38) ← treináveis
Output: 38 logits → softmax
```

Parâmetros totais: **11,2M** | Treináveis: **19.494** (só FC)

DECISÕES E JUSTIFICATIVAS

Backbone ImageNet congelado

Reduz overfitting num dataset de tamanho médio. Features pré-treinadas já capturam textura e bordas relevantes para lesões foliares.

ResNet-18 (não VGG/InceptionV3)

11M vs 138M parâmetros, adequado ao hardware acadêmico. Conexões residuais previnem vanishing gradient mesmo com backbone congelado.

Resultado alcançado

color: 94,78% acc · F1=0,947 · BalAcc=0,947 · 38 classes · 10.709 imagens de teste

Metodologia: Pipeline de Processamento

Aquisição
PlantVillage
3 versões

→

Pré-proc.
Resize 224×224
Norm. ImageNet

→

Segm. ExG
2G−R−B > 0,1
máscara de folha

→

ResNet-18
TL · FC 512→38
Adam + StepLR

→

Ensemble
Stacking
LogReg meta

- **Data augmentation:** flip horizontal, rotação ±15°, ColorJitter, para diversificar o domínio sem adicionar dados externos
- **ExG mitiga viés de fundo:** isola a folha do fundo uniforme, mas perde informação de cor da lesão
- **Adam + StepLR:** LR=1×10^{-3}, decay 0,5× a cada 3 epochs, convergência estável em 10 epochs
- **Meta-classificador:** LogisticRegression (L2, C=1) treinada nas probabilidades softmax → features 76-dim (38+38)

Paralelismo em 3 Níveis

NÍVEL 3 · DISTRIBUÍDO · RAY CLUSTER

3 Ray Actors · 2 nós · 2 GPUs

Cada actor treina 1 versão independente (color / grayscale / segmented). Ray agenda por disponibilidade de GPU. Comunicação apenas na coleta dos resultados finais, sem overhead de gradiente entre actors.

NÍVEL 2 · PARALELO CPU · DATALOADER

4 workers de I/O simultâneos por actor (sweet spot empírico)

Processos separados carregam e transformam imagens em paralelo enquanto a GPU processa o batch anterior (pipeline CPU/GPU). Benchmark: 4 workers → 2,05× speedup em 60 batches × 128 imagens.

NÍVEL 1 · PARALELO GPU · CUDA

Batch de 128 imagens processado em paralelo nos cores CUDA

Operações matriciais (forward + backward) paralelizadas automaticamente pelo PyTorch. `pin_memory=True` reduz latência de transferência CPU→GPU.

Resultados: Modelos Individuais

AVALIAÇÃO EM COLOR_TEST.TXT · 10.709 IMAGENS

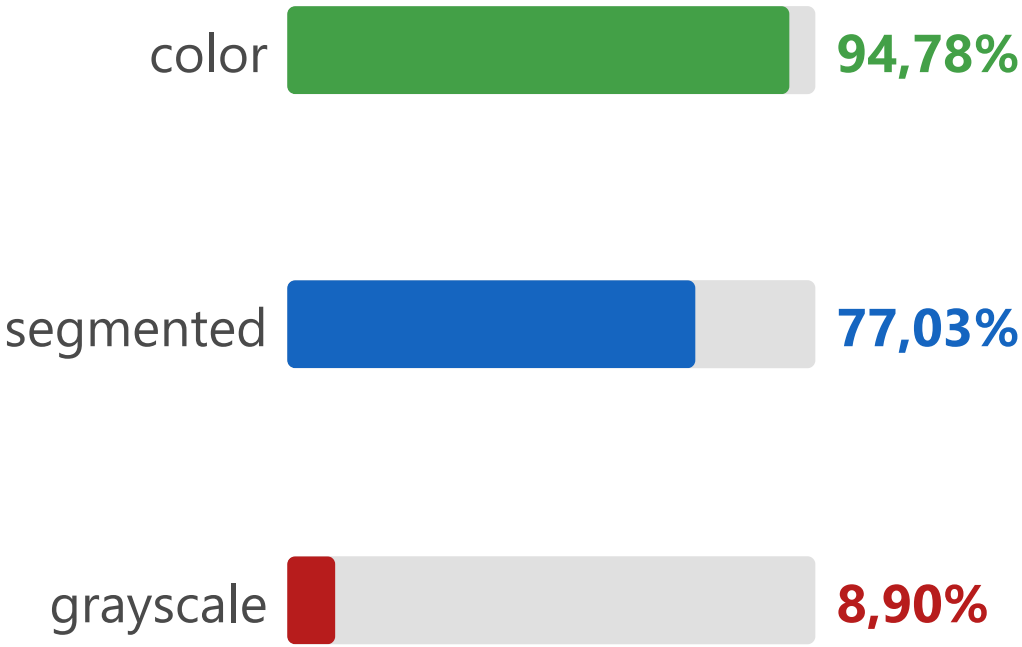

Métricas color: F1=0,947 · Precisão=0,949 · Recall=0,946 · BalAcc=0,947

color (94,78%): treinado e avaliado em RGB colorido. Melhor modelo individual, meta de 90% superada.

grayscale (8,90%) · distribution shift: treinado em escala de cinza, avaliado em imagens coloridas. Colapso total de generalização por incompatibilidade de domínio.

segmented (77,03%): ExG remove o fundo mas perde a cor da lesão. Acurácia intermediária, mais robusto a viés de background.

Resultados: Ensemble

COMPARAÇÃO EM COLOR_TEST.TXT

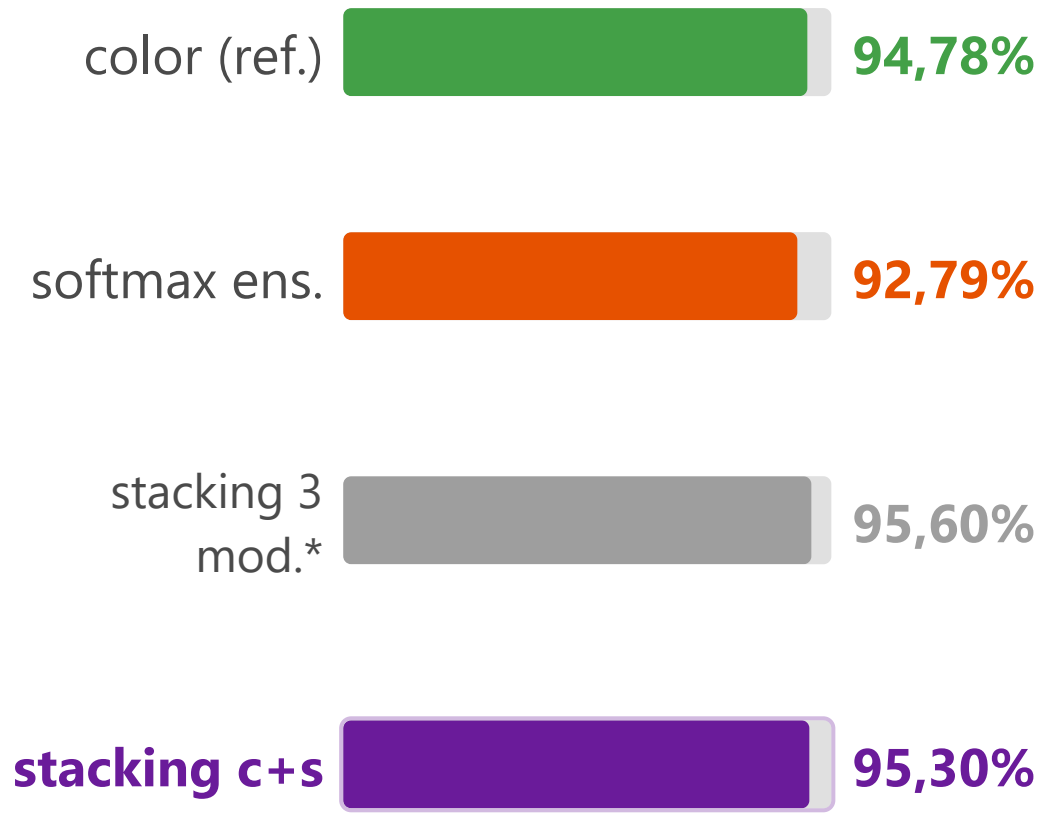

* stacking 3 modelos: inclui modelo grayscale avaliado fora do seu domínio de treino

Stacking color+segmented (+0,52 pp): ambos treinados e avaliados em imagens coloridas. O meta-classificador extrai informação de textura complementar ao modelo color.

Softmax ensemble não supera: grayscale com distribution shift contamina a média de probabilidades, puxando o vetor para distribuição incorreta.

Meta-classificador: LogisticRegression (L2, C=1) treinada nas 76 probabilidades softmax (38+38) dos modelos color e segmented.

Escalabilidade Forte: Mesmo Volume, Mais Workers

Nível 2: DataLoader Workers

60 batches × 128 imgs · GPU dedicada (benchmark isolado)

Workers	Tempo (s)	Speedup	Eficiência
0 (serial)	15,6	—	—
1	17,1	0,91×	91%
2	9,5	1,64×	82%
4 ✅ sweet spot	**7,6**	**2,05×**	**51%**
8	8,2	1,91×	24%

Nível 3: Ray Cluster · Treino Completo

3 modelos · 10 epochs · BATCH=128 · mesmo dataset

Configuração	Tempo	Speedup	Eficiência
1 nó (sequencial)	28,1 min	1,00×	—
2 nós (paralelo)	**20,0 min**	**1,41×**	**47%**

Eficiência 47%: 2 GPUs para 3 actors; 1 actor aguarda GPU livre. A fração serial de agendamento limita o ganho máximo.

Escalabilidade Fraca: Trabalho Proporcional aos Workers

RAY ACTORS: ANÁLISE

Actors	Trabalho	T/actor	Efic. fraca
1 actor	1 versão (color)	~9,4 min	100%
3 actors	**3 versões distintas**	**~9,4 min**	**~100%**

Eficiência fraca ≈ 100%: cada actor processa 1 versão independente. Não há comunicação de gradientes nem sincronização entre actors durante o treino.

INTERPRETAÇÃO

Modelo embarrassingly parallel

As 3 versões são tarefas totalmente independentes. O tempo por actor depende só da carga local, sem crescer com o número de workers.

Contraste com a escalabilidade forte

Fraca ≈ 100% confirma que o design é correto. A forte abaixo de 100% se deve à contenção de hardware (2 GPUs para 3 actors), não ao algoritmo.

Limitações: Viés de Background e Generalização

PROBLEMAS RECONHECIDOS

- **Viés de fundo controlado:** Noyan (2022) demonstrou que 8 pixels do background atingem 49% de acurácia; modelo caiu de 99% para 31% em imagens in-the-wild.
- **Sem validação em campo real:** imagens outdoor têm fundo verde, iluminação variável, oclusão parcial: domínio completamente diferente do laboratorial.
- **Distribution shift grayscale:** treinamento em escala de cinza e inferência em RGB causou colapso total (8,90%).

MITIGAÇÕES E PRÓXIMOS PASSOS

ExG Segmentation: remove fundo via 2G−R−B > 0,1. Resultado: 77,03%, menor que color mas mais robusto a variações de background.

Data augmentation: flip, rotação ±15°, ColorJitter durante treino, sem simular fundo real de campo mas aumentando a diversidade.

Sprint 3: avaliar generalização em dataset de campo real para medir degradação fora do domínio PlantVillage.

Cronograma

Sprint 1

Fundamentos e Proposta

Mar 2026 ✅

Revisão da literatura · Dataset PlantVillage · Pipeline inicial · Objetivos definidos · Apresentação (7 slides)

Sprint 2

Implementação e Resultados Intermediários

Mai 2026 🔄

ResNet-18 + Ray cluster + Ensemble stacking · Escalabilidade forte e fraca · Métricas empíricas · Esta apresentação

Sprint 3

Finalização, Avaliação e Entrega

Jun 2026

Fine-tuning Layer3+Layer4 · Avaliação em dataset de campo real · Análise por classe · Relatório final · GitHub público · Pitch (3–5 min)

Conclusões Intermediárias

94,78%
acurácia · color · 38 classes

1,41×
speedup Ray · 2 nós

+0,52 pp
ensemble stacking vs. melhor individual

O QUE FOI ALCANÇADO NA SPRINT 2

- Acurácia de 94,78% em 38 classes (color), meta de qualidade atingida com backbone congelado e apenas 19.494 parâmetros treináveis
- Stacking color+segmented supera o melhor modelo individual em +0,52 pp, comparação metodologicamente justa entre modelos de mesma entrada
- Speedup Ray: 1,41× (2 nós) · DataLoader: 2,05× (4 workers) · Escalabilidade fraca: ~100% (embarassingly parallel)

Referências

[1] HUGHES, D. P.; SALATHÉ, M. An open access repository of images on plant health to enable mobile disease diagnostics. *arXiv*:1511.08060, 2015.

[2] MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, p. 1419, 2016.

[3] HE, K. et al. Deep residual learning for image recognition. *IEEE CVPR*, p. 770–778, 2016.

[4] SHOAIB, M. et al. An advanced deep learning models-based plant disease detection: a review of recent research. *Frontiers in Plant Science*, v. 14, 2023. DOI: 10.3389/fpls.2023.1158933

[5] NOYAN, M. A. Uncovering bias in the PlantVillage dataset. *arXiv*:2206.04374, 2022.

[6] BARBEDO, J. G. A. Deep learning applied to plant pathology: the problem of data representativeness. *Tropical Plant Pathology*, v. 47, p. 85–94, 2022.

[7] FAO. *The State of Food and Agriculture 2021*. Food and Agriculture Organization of the United Nations, 2021.

Obrigado!

The Green Grid · Sprint 2 · Grupo 12 · 2026.1

Arthur Clemente · Diego Moreira · Felipe Vilhena · Iago Fereguetti · Luan Carrieiros · Lucas Hauck